Détection de compte suspects sur Twitter

CECILLE Aurélien, DELLA VEDOVA Thomas, GILLOT Francois, JOBARD Timothée, ZRIG Hazem

Sommaire

- Introduction
- Data exploration et traitement des données
- Approche non supervisée
- Approche supervisé
- · Comparaison des deux méthodes
- · Conclusion

Introduction

Data exploration et traitement des données


Traitement sous MongoDB

```
_id: ObjectId("5ee1fb796ebd3103e39bde36")
  created date: "2018-06-14 04:14:25"
  current time: 1528942465150
> quoted_status: Object
 in_reply_to_status_id_str: null
 in_reply_to_status_id: null
  created at: "Thu Jun 14 02:14:24 +0000 2018"
  in_reply_to_user_id_str: null
  source: "<a href="http://twitter.com/download/iphone" rel="nofollow">Twitter fo..."
  quoted_status_id: 1007083141671026689
 retweet_count: 0
  retweeted: false
  geo: null
 filter_level: "low"
 in_reply_to_screen_name: null
 is_quote_status: true
 id_str: "1007083806053068801"
 in reply to user id: null
 favorite_count: 0
  id: 1007083806053068801
 text: "Aula! Nós somos a história! https://t.co/x0r46v3FOS"
  place: null
> quoted_status_permalink: Object
 lang: "pt"
  quote_count: 0
```

Exploration de critères pertinents

```
$group
                                               ⊕ +
                                                              Output after $group stage () (Sample of 20 documents)
      id: '$id',
      nom: {
                                                                    id: 519131046
                                                                                                                                  id: 39598451
        $max: '$name'
                                                                    nom: "JoseLikesGatos"
                                                                                                                                  nom: "iktripz"
                                                                    age: 72827
                                                                                                                                  age: 97577
      age: {
                                                                    mentions_avg: 1
                                                                                                                                  mentions_avg: 1
        $min: '$age'
                                                                   hashtag_avg: 1
                                                                                                                                  hashtag_avg: 6
      mentions_avg: {
                                                                   tweets_urls:0
                                                                                                                                  tweets_urls:0
        $avg: {
                                                                   tweets_count: 1
                                                                                                                                  tweets count: 2
11
         $size: '$entities.user mentions'
                                                                 ▼ tweets_differents: Array
                                                                                                                               ▼ tweets_differents: Array
12
                                                                      0: "RT @goldenxgen: i'm so fucking ready for
                                                                                                                                    0: "RT @ONTV_NIGERIA: Who is #Mourinho tipping for
13
14 -
                                                                        tomorrow!!!! let's fucking go..."
      hashtag_avg: {
                                                                                                                                       glory in #Russia? See t..."
15 🕶
        $avg: {
                                                                                                                                    1: "RT @ONTV_NIGERIA: #Argentina or #Portugal? -
                                                                  ▶ all_tweets: Array
         $size: '$entities.hashtags'
16
                                                                   friends count: 419
                                                                                                                                      Jose #Mourinho predicts #..."
17
                                                                                                                                ▶ all_tweets: Array
18
                                                                                                                                  friends_count: 2182
      tweets_urls: {
20
       $sum: '$urls count'
21
      tweets_count: {
23
       $sum: 1
24
25
     tweets differents: {
26 🕶
27
        $addToSet: '$text'
28
29 🕶
     all tweets: {
30
        $push: '$text'
31
32 🕶
     friends_count: {
       $max: '$friends count'
```

Graphes de relations des premiers critères choisis



Recherche de nouveaux indicateurs plus pertinents

$$Visibility = \frac{\sum_{E \in \{@,\#\}} Avg(E) \cdot C(E)}{140}$$

avec C(E) : cout moyen de caractère nécessaire pour une référence de @ ou # (=11,5)

$$Aggressiveness = \frac{f_{tweets} + f_{friends}}{350}$$

 $avec f_{tweets}$: fréquence des tweets publiés par heure


f friends: fréquence du nombre d'amis ajoutés par heure

350 : nombre d'actions maximum possibles imposé par l'API


2 nouveaux indicateurs calculés

```
$addFields
                                                童
                                                               Output after $addFields stage ( (Sample of 20 documents)
                                                     +
      aggressiveness: {
        $divide:
                                                                    _id: 954793774483431424
                                                                                                                                   _id: 905223162400567296
                                                                                                                                                                                                   _id:
                                                                    nom: "SaddigB25"
                                                                                                                                   nom: "ameisaber"
                                                                                                                                                                                                   nom:
            $sum: [
                                                                    age: 21451
                                                                                                                                   age: 24733
                                                                                                                                                                                                   age:
 6 *
                                                                    mentions_avg: 0
                                                                                                                                   mentions_avg: 0
                                                                                                                                                                                                   ment
                 $divide: [
                   '$tweets_count',
                                                                    hashtag avg: 0
                                                                                                                                   hashtag avg: 6
                                                                                                                                                                                                   hash
 9
                   '$age'
                                                                    tweets_urls:0
                                                                                                                                   tweets_urls:0
                                                                                                                                                                                                   twee
10
                                                                    tweets_count: 1
                                                                                                                                   tweets_count: 1
                                                                                                                                                                                                   twee
11
                                                                    tweets_suspects: 1
                                                                                                                                   tweets_suspects: 1
                                                                                                                                                                                                   twee
12 🕶
13 🕶
                 $divide: [
                                                                  ▶ tweets_differents: Array
                                                                                                                                  tweets_differents: Array
                                                                                                                                                                                                 ▶ twee
14
                   '$friends count'.
                                                                  ▶ all tweets: Arrav
                                                                                                                                  ▶ all tweets: Arrav
                                                                                                                                                                                                 ▶ all
15
                   '$age'
                                                                    friends count: 1881
                                                                                                                                   friends count: 164
                                                                                                                                                                                                   frie
16
                                                                    aggressiveness: 0.0002506709643906045
                                                                                                                                   aggressiveness: 0.000019060711253328404
                                                                                                                                                                                                   aggr
17
                                                                    visibility: 0
                                                                                                                                   visibility: 0.49285362247412523
                                                                                                                                                                                                   visi
18
                                                                    tweets_similaires: 0
                                                                                                                                   tweets_similaires:0
19
                                                                                                                                                                                                   twee
20
          350
                                                                    danger: 1
                                                                                                                                   danger: 1
                                                                                                                                                                                                   dang
21
22
23 🕶
      visibility: {
24 -
        $divide: [
25 🕶
26 -
            $sum: [
27
               '$hashtag avg'
28
               '$mentions avg'
29
30
31
          12.174
32
```

Graphes de relations avec ces nouveaux critères



Graphes de relations en rajoutant le critère danger



Finalisation du traitement des données pertinentes sous MongoDB



Indicateurs finaux

Pour conclure voici nos 4 indicateurs :

$$Aggressiveness = \frac{f_{tweets} + f_{friends}}{350}$$

 $\operatorname{avec} f_{tweets}$: fréquence des tweets publiés par heure

 $f_{friends}$: fréquence du nombre d'amis ajoutés par heure


350 : nombre d'actions maximum possibles imposé par l'API

$$Visibility = \frac{\sum_{E \in \{@,\#\}} Avg(E) \cdot C(E)}{140}$$


avec C(E) : cout moyen de caractère nécessaire pour une référence de @ ou # (=11,5)

$$Spam = \frac{tweets\ similaires}{tweets\ count}$$

Graphes de relation des indicateurs finaux




Augmentation des données




Intérêt de l'ACP?

Variable	1	2	3	4
Pourcentage expliqué	27%	25%	24%	22%

Visualisation des suspects trouvés à la main



Visualisation sur les 1.8 millions de compte du dataset total de tweets




Modèle Non-Supervisé


Matrice de confusion

Valeur à la main	Positif	Négatif
Prédiction		
Positif	Comptes non-suspects correctement prédit (Vrai positif)	Comptes non-suspects incorrectement prédit (Faux positif)
Négatif	Comptes suspects incorrectement prédit (Faux négatif)	Comptes suspects correctement prédit (Vrai négatif)

Algorithme de clustering




Algorithme de détection d'anomalie




Exemples de Faux-Positifs

RT @casinobitcoin: Bet with confidence and the best odds for the #WorldCup with #bitcoin and #adk only at https://t.co/s5Z1cFLQTC $oldsymbol{\mathfrak{D}}$ WORLD CUP SPECIALS $oldsymbol{\mathfrak{D}}$ \n\nGet price boosts, free bets and tons more ahead of Saturday's games in Russia ! \\ \\ \\ \\ \\ \\ \\ \\ \t.co/nEZ2kc8Ddp Science seed\nhttps://t.co/RGDqpW9iPs\n\n#HealthXPh #Jobs #life #love #animals #startup #music #photography #poetry... https://t.co/icKkbYICvN Get 100% up to £50 when you sign up for an account during the #WorldCup ↓\\n\n18+. T&Cs apply.... https://t.co/JwjYDQGXmr We are doing a #WorldCup2018 Challenge Pool. Sign up for free and win some \$\$: https://t.co/zGJoJqMAYd https://t.co/2BvJjOJXCn

Optimisation sur l'ensemble des données




Contamination:



Modèle Supervisé

SVM sur 1700 compte




Données de

1	est: 482	0
	7	21

Données à la

İ	nain: 1614	62
	15	9


SVM sur l'ensemble des données



Données de

1	est: 36147	22
	70	645

Comparaison des deux méthodes



Nonsupervisé Supervisé

Conclusion